

0.1 似然与先验

似然 (Core Task 1, §3.1)。 设 y_i 为第 i 个观测的日租车数量, $x_{i1}, x_{i2} \in [0, 1]$ 分别为经 min-max 归一化后的温度与湿度, $i = 1, \dots, n, n = 360$ 。 y 的经验分布近似对称, 样本均值 $\bar{y} = 4392$, 样本标准差 $s_y = 1936$, 取值范围 $[22, 8555]$ 。我们采用同方差高斯线性回归作为采样模型:

$$y_i | \beta, \sigma \stackrel{\text{ind}}{\sim} \mathcal{N}(\mu_i, \sigma^2), \quad \mu_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2}, \quad \beta = (\beta_0, \beta_1, \beta_2)^\top. \quad (1)$$

我们考察并排除了两种自然的备选。Poisson 似然要求等分散 ($\text{Var} = \mathbb{E}$); y 的经验方差均值比比 1 高出一个数量级, 故 Poisson 模型会得到人为偏窄的可信区间。负二项似然通过引入额外的离散参数来放宽该约束, 但代价是引入非高斯链接函数, 而鉴于 y 的近似对称性, 这一代价并不能换来等价的拟合改进。因此本文采纳 (1) 中的高斯设定, 并将负二项保留为稳健性检查的备选。

先验设定 (Core Task 1, §3.2)。 我们对四个参数指定相互独立的弱信息先验:

$$\beta_j \sim \mathcal{N}(0, \tau_\beta^2), \quad j = 0, 1, 2, \quad \sigma \sim \text{Half-}\mathcal{N}(\tau_\sigma), \quad (2)$$

超参数取 $\tau_\beta = 10,000, \tau_\sigma = 3,000$ 。在 (2) 下, 每个 β_j 的先验均值、中位数与众数皆为零, 先验标准差为 τ_β , 95% 先验可信区间约为 $(-19,600, 19,600)$ 。 σ 的 Half-Normal 先验强制正性约束 $\sigma > 0$, 并具有解析的位置/离散度刻画: $\mathbb{E}[\sigma] = \tau_\sigma \sqrt{2/\pi} \approx 2394$ 、 $\text{SD}(\sigma) = \tau_\sigma \sqrt{1 - 2/\pi} \approx 1808$ 、先验中位数 $\tau_\sigma \Phi^{-1}(0.75) \approx 2024$ 、95 分位 ≈ 5880 (见表 1)。

表 1: 先验分布及其位置/离散度量。

参数	分布	超参数	先验均值	先验标准差
$\beta_0, \beta_1, \beta_2$	正态	$\tau_\beta = 10,000$	0	10,000
σ	Half-Normal	$\tau_\sigma = 3,000$	≈ 2394	≈ 1808

超参数标定。 两个超参数均按数据的经验尺度进行标定。由于 x_{ij} 已归一化至 $[0, 1]$, 协变量 j 的单位变化对应其完整经验范围, 因此可信的系数量级以 $\max_i y_i - \min_i y_i \approx 8.5 \times 10^3$ 为上界。取 $\tau_\beta = 10,000$ 使约 95% 先验质量集中于 $|\beta_j| < 19,600$, 从容覆盖 OLS 估计 $(\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2) \approx (2548, 6796, -2370)$, 只排除那些隐含效应超出 y 经验范围的取值。 $\tau_\sigma = 3,000$ 使 σ 的先验中位数 (≈ 2024) 与经验尺度 $s_y \approx 1936$ 相符, 在大量先验质量所在区域容纳 OLS 残差标准误 $\hat{\sigma}_{\text{OLS}} = 1497$, 并避开反伽马在小尺度下的病态行为。按设计, τ_β 与 τ_σ 皆比第 0.2 节报告的后验标准差大一个数量级, 故似然主导后验, 第 1 节得以对替代设定的敏感性进行有意义的评估。

先验预测检查。 为验证 (2) 在响应自然尺度上的合理性, 我们从 y 的联合先验预测分布中抽取 500 个样本 (图 1)。所得分布近似关于零对称, 跨度约 $\pm 30,000$, 约为经验范围的七倍, 验证了该设定的弱信息性。一部分先验质量落在零以下, 这在物理上不可行, 但作为对 β 施加无约束高斯先验的副作用是可以接受的; 一旦以数据为条件, 该区域所携带的后验概率即可忽略。




图 1: y 的先验预测分布 (500 次联合先验抽样)。虚线分别标记 $y = 0$ 与观测最大值 8555。

0.2 后验推断

将似然 (1) 与先验 (2) 结合, 得到 $(\beta_0, \beta_1, \beta_2, \sigma)$ 的联合后验 $p(\beta, \sigma | \mathbf{y}, \mathbf{X})$ 。该后验没有解析形式: 三个回归系数与未知残差尺度同时存在, 破坏了单系数已知方差情形下的正态-正态共轭性。我们因此用马尔可夫链蒙特卡洛 (MCMC) 进行近似。

MCMC 配置 (Core Task 1, §3.3)。 采样器为 PyMC 5 中的 No-U-Turn Sampler(NUTS), 即 Hamiltonian Monte Carlo 的自调参变体。我们运行 $C = 4$ 条独立链, 每链 $W = 1,000$ 步预热 (warm-up) 与 $T = 2,000$ 步保留, 共得 $S = CT = 8,000$ 个后验样本。预热阶段同时承担两项作用:NUTS 在该阶段自适应步长与对角质量矩阵, 相应抽样在链尚未充分进入高密度区域时取得, 被作为 burn-in 一并丢弃; 因此不再额外移除 burn-in。目标接受概率设为 $\alpha = 0.95$ (高于默认值 0.80) 以抑制散度过渡 (divergent transitions); 采样过程中无散度过渡报告。随机种子固定为 42, 与 Module A 的子抽样种子一致, 从而整套分析流程可由原始数据复现至后验汇总。

收敛诊断。 两项标准诊断表明四条链已收敛至同一后验。其一, 势在尺度缩减因子满足 $\hat{R} = 1.00$ 对所有参数成立, 远低于通行预警阈值 1.01。其二, bulk 有效样本量 $N_{\text{eff}}^{\text{bulk}} \in [3,775, 5,371]$, 远超用于稳定估计中心趋势的经验最低标准 400。轨迹图与自相关的更详细分析见第 3 节, 本节直接进入后验推断。

后验汇总。 表 2 报告每个参数 $\theta \in \{\beta_0, \beta_1, \beta_2, \sigma\}$ 的后验均值 $\hat{\theta} = \mathbb{E}[\theta | \mathbf{y}]$ 、后验标准差与 95% 最高密度可信区间 (HDI)。HDI 优于等尾区间, 因为它始终包含最可能的取值, 并对非对称后验仍然有效。各参数的边际后验密度如图 2 所示, 均近似对称且单峰。

表 2: 基于 $S = 8,000$ 个 NUTS 样本的后验汇总 (4 条链 $\times$ 2,000 保留)。所有 $\hat{R} = 1.00$, 各参数的 bulk ESS 均超过 3,500。

参数	均值	标准差	95% HDI 下限	95% HDI 上限	ESS bulk	$\hat{R}$
β_0 (截距)	2541	382	1799	3324	3,775	1.00
$\beta_1(x_{i1}, \text{温度})$	6784	436	5915	7632	5,371	1.00
$\beta_2(x_{i2}, \text{湿度})$	-2350	555	-3457	-1276	4,181	1.00
σ	1500	56	1393	1610	5,352	1.00

结果解释 (Core Task 1, §3.4)。 系数解释建立在归一化协变量尺度之上: x_{i1} 的单位变化对应数据中的完整温度幅度 (-8 至 39°C , 范围 47°C), x_{i2} 的单位变化对应完整湿度幅度 (从干燥到饱




图 2: $\beta_0, \beta_1, \beta_2, \sigma$ 的边际后验密度; 每条曲线下方的横条标示 95% HDI。

和)。

温度 (β_1)。后验均值 $\hat{\beta}_1 = 6784$, 95% HDI 为 (5915, 7632)。下限高于零超过十三个后验标准差, 故 $\Pr(\beta_1 > 0 \mid \mathbf{y})$ 实际等于 1。归一化温度每提高一个单位, 期望日租车数平均增加约 6,800 辆, 使温度成为模型中占主导地位的解释机制。

湿度 (β_2)。后验均值 $\hat{\beta}_2 = -2350$, 95% HDI 为 (-3457, -1276)。该区间不包含零, 支持湿度对共享单车活动具有可观抑制作用的结论, 与第一节探索性分析中显现的负斜率一致。相对于 β_1 的更宽区间, 反映了数据中较弱的相关性与较小的绝对效应。

截距 (β_0)。后验均值 $\hat{\beta}_0 = 2541$, 95% HDI 为 (1799, 3324)。在 (1) 的参数化下, β_0 表示当两个预测变量同时为零时模型隐含的期望日计数——这是数据中并未实现的预测变量空间角点, 仅出于完整性而保留, 不作实质解释。

残差尺度 (σ)。后验均值 $\hat{\sigma} = 1500$, 95% HDI 为 (1393, 1610)。相对尺度 $\hat{\sigma}/\bar{y} \approx 0.34$ 表明温度与湿度合在一起, 仍留有约三分之一的 y 日标准差未被解释, 与 OLS 基准给出的中等决定系数 $R^2 = 0.405$ 相符。这部分残差变异归因于日历效应、节假日及其他气象协变量; 为契合项目所规定的两预测变量设定, 这些协变量被有意省略。